MediFlow AI

Arquitectura de un agente conversacional de agendamiento clínico

Evaluación Parcial 2 · ITY1102 · 30%

Demis Zúñiga · Bruno Burgos · Matías Cortez
Duoc UC · 26 de octubre de 2026

MediFlow AI: agendar horas conversando

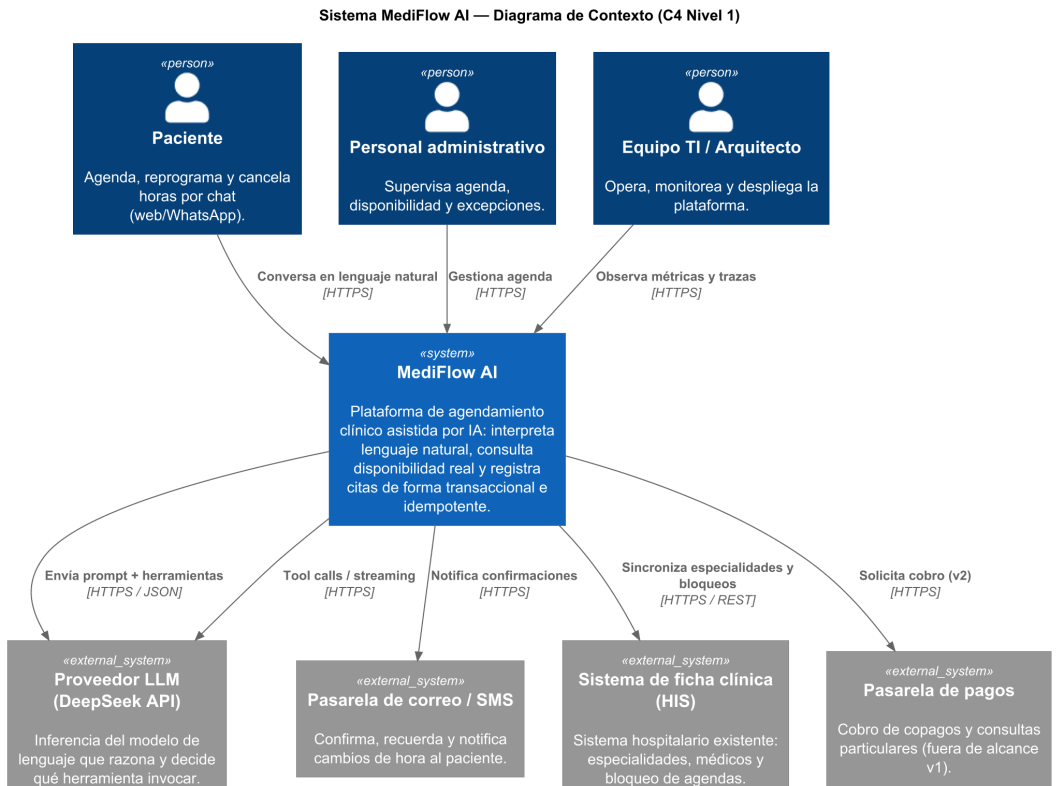
El paciente escribe o habla en lenguaje natural —sitio web o WhatsApp— y el sistema **interpreta la intención, consulta disponibilidad real, registra la cita y notifica**. Sin formularios, menús ni call center.

La arquitectura de esta entrega resuelve cuatro problemas que un prototipo no enfrenta: **concurrencia sobre el mismo cupo**, **reanudación tras caída**, **datos de salud sensibles** y **costo variable por token**.

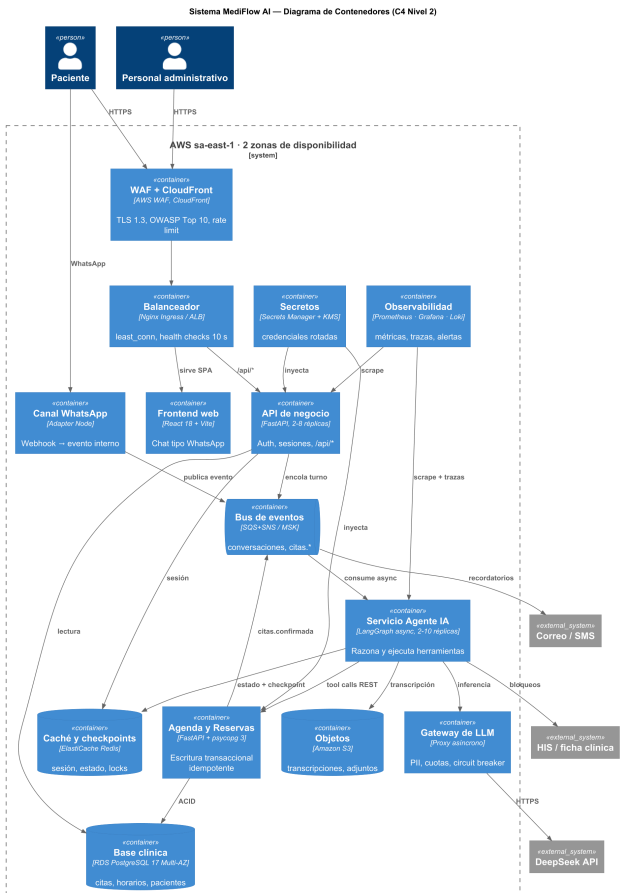
72.000
turnos al mes (300 conversaciones/día × 8)

USD 0,0523
costo total por turno, canal incluido

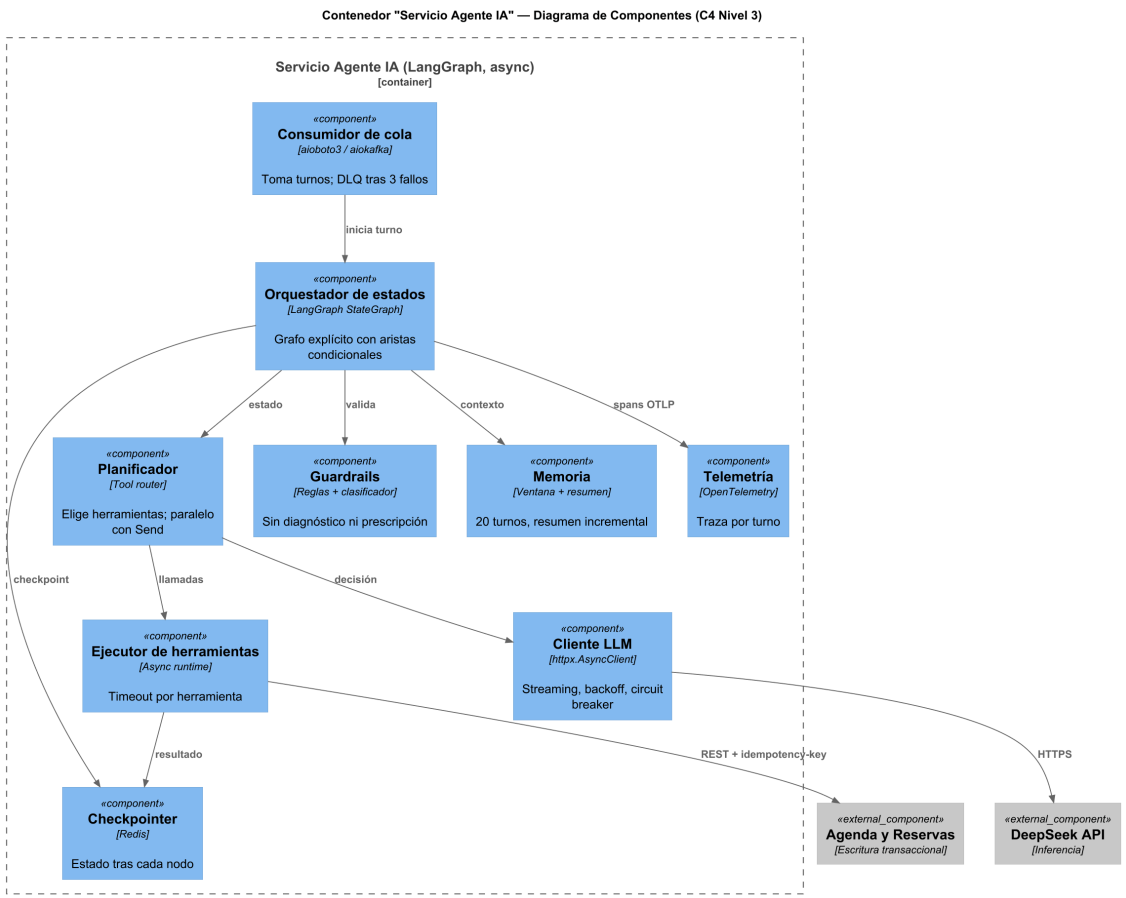
Contexto del sistema



Contenedores: seis unidades desplegables



Componentes del servicio de agente



Microservicios y arquitectura dirigida por eventos

Microservicios con contenedores

- Cada servicio con su ciclo de despliegue y su propio escalado.
- API de negocio como única puerta de escritura.
- Gateway de LLM aísla proveedor, cuotas y enmascarado de datos.
- Sin base de datos compartida entre servicios.

Event-Driven

- El webhook de WhatsApp responde 200 en menos de 100 ms y publica el turno.
- SQS desacopla el pico de cinco veces la media del consumo del agente.
- Cola de mensajes muertos tras tres fallos: ningún turno se pierde en silencio.
- SNS notifica al paciente y registra el evento de dominio.

Recursos y costo mensual real (sa-east-1)

Recurso	Especificación	USD/mes
EKS	cluster gestionado 1 × 730 h	73,00
EC2 app	m6i.xlarge 4 vCPU / 16 GiB × 3	670,14
EC2 agente	m6i.xlarge × 2	446,76
RDS	db.m6g.large Multi-AZ + gp3 200 GB	391,28
ElastiCache	cache.m6g.large Multi-AZ × 2	309,52
ALB + NAT	1 ALB + 10 LCU-h · 2 NAT	240,90
Resto	S3/CloudFront, SQS, secretos, EBS	165,59
Infraestructura	**730 h/mes on-demand**	**2.297,19**
Canal WhatsApp	72.000 mensajes de servicio a USD 0,0200	1.465,00
Total del sistema	**USD 0,0523 por turno**	**3.762,19**

Por qué este tamaño

- 300 conversaciones diarias con pico de 5× definen CPU, no memoria.
- La inferencia ocurre fuera: no se compra GPU; una g4dn.xlarge queda como opción evaluada para fine-tuning, no para operación.
- Multi-AZ en datos y caché sostiene RPO 5 min / RTO 30 min.
- El canal pesa 39 % del costo: Meta cobra cada respuesta desde el 1 de octubre de 2026, con 1.000 mensajes de servicio gratis al mes.
- Por eso se agrupa la respuesta en un mensaje y no se usan plantillas de marketing.

Kubernetes, escalado y balanceo

EKS 1.31

- Node group m6i.xlarge de 3 a 6 nodos.
- 2-8 réplicas del API y 2-6 del servicio de herramientas.
- HPA por CPU y por profundidad de cola; PDB para no caer completo.
- Requests y limits por pod; sondas de vida y de disponibilidad separadas.

Balanceo

- ALB con health check HTTP sobre /api/health cada 10 s, umbral 3.
- Nginx de entrada con **least_conn**: la conexión del agente dura más que una consulta y no conviene repartirla por turnos.
- Retiro inmediato del destino no sano; drenaje de 30 s antes de terminar un pod.
- Despliegue progresivo: si el health check falla, el rollout se detiene.

TRANSVERSAL

Seguridad, observabilidad y alta disponibilidad

Plan de seguridad (10 puntos, 3 fases)

- **Gobierno:** dato de salud como sensible (Ley 19.628 y 21.719), modelado de amenazas por contenedor, confianza cero con mTLS.
- **Datos y modelo:** minimización, seudonimización en logs, 60 casos adversarios en CI.
- **Operación:** guardrails de entrada y salida, aislamiento de entornos, monitoreo de deriva, red teaming trimestral.

Monitoreo y continuidad

- Prometheus + Grafana + Loki con trazas OpenTelemetry por turno.
- Alerta si la tasa de error supera 2 % en 5 min o si p95 supera 4 s.
- RPO 5 min (standby síncrona) y RTO 30 min (failover automático).
- Respaldo probado: la restauración se ensaya, no se supone.

Cinco decisiones que sostienen el diseño

Decisión	Alternativa descartada	Por qué
Orquestación con EKS	ECS Fargate	HPA por profundidad de cola, NetworkPolicy de egreso y despliegue progresivo; el plano de control cuesta USD 73 al mes sobre un total de 3.762.
PostgreSQL con restricción de exclusión	Base NoSQL	El solapamiento de horas se impide en la base, no en el código: un solo cupo activo por médico y hora, incluso con dos reservas simultáneas.
SQS como cola	Kafka	72.000 turnos al mes no requieren retención de flujo ni reprocesamiento; operar un clúster de Kafka no se paga con ese volumen.
Idempotencia por clave y huella	Control solo en la aplicación	Si el modelo reintenta o el paciente reenvía, la misma clave devuelve la misma cita en lugar de duplicarla.
Ciclo del agente como grafo de estados	Cadena de llamadas al modelo	Con un checkpoint por nodo el turno se reanuda donde quedó tras la caída de un pod, y cada decisión del agente queda auditable.

Cada decisión responde a un requisito de calidad del capítulo 10 del informe: concurrencia, disponibilidad, costo y auditabilidad. Las cinco están implementadas en el repositorio, no solo dibujadas.