Guion de defensa corregido — MediFlow AI (EP2 ITY1102)

Duración: 10 minutos · apuntar a 9:00 · 10 diapositivas

> Correcciones aplicadas sobre el guion original: precisión terminológica ("dimensionamos", no "medimos"), separación entre las seis unidades desplegables y la infraestructura del diagrama, distinción entre concurrencia e idempotencia, el rol real de SNS, y las frases de remate que faltaban.

Reparto: Demis (apertura, C4 y comparación técnica) · Bruno (dimensionamiento y costos) · Matías (patrones, Kubernetes, seguridad). Ajustar a quién domina cada tema.

Antes de empezar (2 minutos)

1. Abrir el PDF de la presentación en pantalla completa; el informe en otra pestaña (por si piden un diagrama o una tabla).
2. Verificar que el proyector no recorte los bordes: la presentación es 16:9.
3. Cronómetro a la vista. 10 minutos es el máximo.
4. Tener claro quién habla en cada bloque: si dos empiezan a la vez, se pierden 20 segundos y la nota es de equipo.

0:00 – 1:00 · Diapositivas 1 y 2 — Apertura

> "Buenos días. Presentamos **MediFlow AI**: agendamiento de horas médicas conversando, por web o WhatsApp. El paciente escribe en lenguaje natural, el sistema interpreta la intención, consulta disponibilidad real, **registra la cita** y notifica. Sin formularios ni menús.
>
> Esta entrega **no diseña el flujo: diseña la arquitectura que lo sostiene en producción.** Lo dimensionamos sobre **72.000 turnos al mes** —300 conversaciones diarias por 8 turnos— con un **pico de cinco veces la media**, y ese pico justifica todo lo que viene después.
>
> La arquitectura responde a cuatro problemas que un prototipo no enfrenta: **concurrencia sobre el mismo cupo, reanudación si un pod cae a mitad de la conversación, datos de salud sensibles y costo variable por token.**
>
> El resultado: **5,23 centavos de dólar por turno**, canal incluido."

No digas: "medimos el costo" (fue un cálculo con precios de lista y volumen proyectado), ni "atención al cliente 24/7" como si fuera un requisito del caso.

1:00 – 2:30 · Diapositiva 3 — C4 Nivel 1 (contexto)

- El sistema como **una sola caja**, en el centro. Arriba, quién lo usa; abajo, de qué depende.
- **Los cinco vecinos:** paciente · personal administrativo (recepción) · proveedor de LLM (DeepSeek) · **HIS** / **ficha clínica** · pasarela de correo/SMS. La pasarela de pagos queda **fuera del alcance** de esta versión.
- El paciente entra por web o WhatsApp; **no accede a la operación interna**.

Frase de remate (decirla sí o sí):

> "El sistema **no reemplaza la agenda del HIS: escribe en ella**. Por eso la frontera del contexto técnico está en la **API de negocio**, no en la base de datos."

Si preguntan por el HIS: es la fuente autoritativa de especialidades, médicos y bloqueos. Nosotros no duplicamos esa verdad, la consultamos y le escribimos a través de su API.

2:30 – 4:00 · Diapositiva 4 — C4 Nivel 2 (contenedores)

Primero las seis unidades desplegables (es lo que dice el título de la slide):

1. Canal WhatsApp
2. Frontend web
3. API de negocio
4. Servicio Agente IA
5. Agenda y Reservas
6. Gateway de LLM

Después, lo que además muestra el diagrama:

- **Infraestructura que las soporta:** WAF + CloudFront (TLS 1.3, OWASP Top 10, rate limit por IP), balanceador ALB (health check cada 10 s), secretos con KMS y rotación a 90 días, observabilidad (Prometheus, Grafana, Loki).
- **Datos:** PostgreSQL (RDS 17 Multi-AZ), Redis (sesión, estado, checkpoints), bus de eventos SQS + SNS.

Frase de remate (es la que da nota en esta slide):

> "El servicio de agente escala con la conversación; la agenda escala con las escrituras. Si fueran el mismo contenedor, escalarían juntos y pagaríamos de más."

Si preguntan "¿WAF y ALB son contenedores C4?" — respuesta honesta y corta:

> "En el diagrama están dibujados con la misma notación porque son parte del despliegue; en sentido estricto son servicios gestionados de infraestructura. Las **seis unidades desplegables propias** son las que nombré primero."

No digas: que el ALB o el WAF son "contenedores" sin aclarar. Es el error que la pauta marca como más común.

4:00 – 5:00 · Diapositiva 5 — C4 Nivel 3 (componentes del agente)

Recorrer el ciclo señalando el diagrama: **consumidor de cola → orquestador de estados → planificador → ejecutor de herramientas → guardrails → respuesta.**

Dos piezas que un prototipo no tiene y una evaluación sí exige:

- **Checkpointer:** guarda el estado después de cada nodo. Si el pod muere, el turno se reanuda donde quedó.
- **Guardrails:** ni diagnóstico ni prescripción. Entrada y salida filtradas.

Cada decisión del agente queda **auditable**: qué herramienta llamó, con qué argumentos, cuántos tokens.

5:00 – 6:00 · Diapositiva 6 — Patrones

Microservicios: - Cada servicio con su ciclo de despliegue y su propio escalado. - **API de negocio como única puerta de escritura.** Sin base compartida entre servicios. - El gateway de LLM aísla al proveedor: cuotas, reintentos y **enmascarado de datos** antes de salir.

Event-Driven: - El webhook de WhatsApp responde **200 en menos de 100 ms** y publica el turno; el trabajo pesado ocurre después. - **SQS absorbe el pico de 5×**; cola de mensajes muertos tras tres fallos: ningún turno se pierde en silencio. - **SNS publica el evento** (cita creada, movida o cancelada). El que le avisa al paciente es la **pasarela de correo/SMS, que está suscrita**; SNS no le escribe directamente.

Si preguntan por qué no monolito:

> "El pico es de la conversación, no de la agenda. Separarlos permite escalar solo lo que se satura."

6:00 – 7:00 · Diapositiva 7 — Dimensionamiento y costos

Método primero, números después:

> "Precios on-demand reales de **sa-east-1**, **730 horas** al mes, tomados de la lista de precios de AWS. **Dimensionamos**, no estimamos a ojo."

Concepto	USD/mes
Infraestructura (EKS, EC2, RDS, ElastiCache, ALB+NAT, resto)	**2.297,19**
Canal WhatsApp (72.000 mensajes × 0,02)	**1.465,00**
Total del sistema	**3.762,19**
Costo por turno	**0,0523**

El dato que conviene decir en voz alta:

> "El canal pesa **39 % del costo**. Meta empezó a cobrar las respuestas del bot el 1 de octubre de 2026: 0,02 dólares por mensaje en Chile, con mil gratis al mes. Por eso agrupamos la respuesta en **un solo mensaje** y no usamos plantillas de marketing, que cuestan **4,4 veces más**."

Sin GPU — decirlo antes de que lo pregunten:

> "La inferencia ocurre en el proveedor. Una g4dn.xlarge está evaluada **solo para fine-tuning**, no para operación. Comprar GPU para inferencia remota sería gasto sin uso."

Si preguntan qué se recorta primero:

> "Los nodos de aplicación bajan a 2 y ElastiCache a una réplica: unos **USD 520** de ahorro, con degradación de disponibilidad, no de función."

7:00 – 8:00 · Diapositiva 8 — Kubernetes y balanceo

- **EKS 1.31**, node group de **3 a 6 nodos m6i.xlarge**, separados por tipo de trabajo (app, agente, observabilidad).

- **HPA por CPU y por profundidad de cola**: el pico de 5× no exige servidores ociosos todo el mes. **PDB** para que un mantenimiento no tumbe todo.
- **ALB** con health check HTTP sobre `/api/health` cada **10 s**, umbral 3.
- **Nginx con `least_conn`** — y explicar por qué: *"la conexión del agente dura más que una consulta; repartir por turnos dejaría un pod con cinco conversaciones y otro con una"*.
- **Drenaje de 30 s** antes de terminar un pod, para no cortar una conversación a medias.
- Rollout progresivo: si el health check falla, el despliegue se detiene y quedan los pods viejos.

8:00 – 9:00 · Diapositiva 9 — Seguridad, observabilidad y alta disponibilidad

Los **10 puntos en tres fases**, nombrando la fuente: la guía de la actividad 2.1 del curso.

- **Gobierno:** dato de salud como sensible (**Ley 19.628 y 21.719**), modelado de amenazas por contenedor, confianza cero con mTLS.
- **Datos y modelo:** minimización, **seudonimización en logs**, 60 casos adversarios en CI, guardrails de entrada y salida.
- **Operación:** aislamiento de entornos, monitoreo de deriva, red teaming trimestral.

Evidencia medida: 20 ataques ejecutados 7 veces (**140 turnos**), cero fugas y cero respuestas vacías; el contador se ve en `/api/guardrails`.

Continuidad: RPO 5 min y **RTO 30 min**, con la restauración **probada, no supuesta**.

Monitoreo: Prometheus, Grafana y Loki con trazas OpenTelemetry por turno. Alerta si el error supera el **2 % en 5 min** o el **p95 supera 4 s**.

9:00 – 10:00 · Diapositiva 10 — Cinco decisiones y cierre

Una frase por fila, sin leer la tabla completa:

1. **EKS en vez de ECS Fargate** — HPA por profundidad de cola, NetworkPolicy de egreso y despliegue progresivo; el plano de control son USD 73 sobre 3.762.
2. **PostgreSQL con restricción de exclusión en vez de NoSQL** — el solapamiento se impide en la base, no en el código.
3. **SQS en vez de Kafka** — 72.000 turnos al mes no pagan operar un clúster de Kafka.
4. **Idempotencia por clave y huella en vez de control solo en la aplicación** — el reintento devuelve la misma cita, no una nueva.
5. **Grafo de estados en vez de cadena de llamadas** — con checkpoint el turno se reanuda; cada decisión queda auditable.

Cierre:

> "La arquitectura queda documentada, dimensionada en **USD 3.762 al mes** con el canal incluido y con un plan de seguridad verificable. Quedamos atentos a sus preguntas."

Preguntas probables

¿Cuáles son las seis unidades desplegables? Canal WhatsApp, frontend web, API de negocio, servicio agente, agenda/reservas y gateway de LLM. La infraestructura (WAF, ALB, secretos, observabilidad) y los datos (PostgreSQL, Redis, bus) están en el diagrama pero no son unidades propias.

¿Por qué EKS y no ECS, si cuesta más? El plano de control son USD 73 al mes dentro de 2.297 (3 %). A cambio: HPA por métrica de cola, NetworkPolicy de egreso y despliegues progresivos. ECS obligaría a construir eso a mano.

¿Dónde se cae este diseño si el tráfico se multiplica por diez? Primero la base de datos: la escritura transaccional de citas. La mitigación está en el bloqueo por cupo y el índice único parcial; después, réplicas de lectura y partición por fecha.

¿Cómo se evita que dos pacientes tomen la misma hora? Dos problemas distintos. **Concurrencia:** dos pacientes por el mismo cupo, se resuelve con `SELECT FOR UPDATE` y restricción de exclusión en horarios. **Duplicado:** el mismo paciente reintentando, se resuelve con clave de idempotencia y huella SHA-256. La primera es de la base; la segunda, de la aplicación.

¿Qué pasa si el proveedor de LLM se cae? Circuit breaker en el gateway, reintentos con retroceso y respuesta degradada: se ofrece la agenda sin lenguaje natural. La cita no se pierde, se deriva al flujo clásico.

¿Cómo se protege un dato de salud de la fuga en los logs? Enmascarado en el gateway antes de salir al proveedor, seudonimización en logs y retención de 90 días con borrado programado. El dato identificable no se escribe en texto plano.

¿Cómo se mide que la arquitectura cumple? Tablero en Grafana con error, p95, deriva de intención y profundidad de cola; alerta si el error supera el 2 % en 5 min o el p95 supera 4 s.

¿Por qué no usaron GPU si es un sistema de IA? Porque el modelo no se entrena ni se sirve localmente. El costo por turno está en el token, no en el hardware; una GPU ociosa sería el error clásico de dimensionamiento.

¿Qué no alcanzaron a hacer? Ser honestos y acotados: el motor de reservas está implementado y probado (reserva doble rechazada, turno reanudado, imagen con healthcheck sano), pero la **conexión completa del flujo conversacional con las herramientas de escritura** queda como trabajo siguiente.

> **Nunca decir "está todo listo".** La pregunta siguiente sería una demostración en vivo.

Los números que no se olvidan

- **72.000** turnos/mes = 300 conversaciones/día × 8 turnos
- **5×** el pico sobre la media
- **2.297,19** USD/mes de infraestructura
- **1.465,00** USD/mes de canal WhatsApp
- **3.762,19** USD/mes total
- **0,0523** USD por turno
- **39 %** del costo es el canal
- **0,02** USD por mensaje de servicio en Chile
- **73** USD/mes el plano de control de EKS
- **RPO 5 min** / **RTO 30 min**
- **140** turnos de pruebas adversarias, cero fugas
- **2 % en 5 min** y **p95 4 s**: los umbrales de alerta

Errores que ya corregimos

Antes	Ahora
"Medimos el costo de operación"	"Dimensionamos con precios on-demand de sa-east-1"

"Mensajes duplicados" como uno de los cuatro problemas	"Concurrencia sobre el mismo cupo"; el duplicado es otro problema (idempotencia)
Nivel 2 = WAF, CloudFront, ALB, Secretos	Nivel 2 = las **seis unidades**; WAF, ALB, secretos y observabilidad son infraestructura del diagrama
"Se cae un contenedor"	"Se cae un **pod**"
"SNS manda el mensaje al paciente"	SNS publica el evento; la pasarela de correo/SMS suscrita es la que envía
"sql inyection"	"inyección SQL"; XSS = "equis-ese-ese"
Faltaba el número de la slide 2	Se dice: **0,0523 USD por turno**
Faltaba el marco EP2	"No diseña el flujo: diseña la arquitectura que lo sostiene en producción"
Faltaba la frase del HIS	"No reemplaza la agenda del HIS: escribe en ella; la frontera está en la API de negocio"